

Промышленный краткосрочный прогноз выработки ВЭС (24-48 ч, почасовой): как это реально делают ML-команды TL;DR

- **Канонический продакшн — это NWP-to-power пайплайн:** архивный прогноз погоды «as-of-time» → приведение ветра к высоте ступицы и коррекция плотности воздуха → ML-модель (в проде почти всегда градиентный бустинг на NWP-признаках, а не глубокие сети) → почасовые квантили → бэктест rolling-origin по циклам 00/06/12/18 UTC. Для вашего кейса (одна турбина, Казахстан, три канала SCADA, нет направления/давления, 6,6% пропусков) оптимальна связка **Open-Meteo Historical Forecast / ECMWF IFS + LightGBM с прямым multi-horizon quantile** и двухступенчатой архитектурой «физическая кривая мощности + ML-коррекция ошибки NWP».
- **Главная ловушка — train/serve skew:** история содержит ветер с анемометра гондолы, а прод — NWP-ветер 10/100 м. Best practice — **не подавать в модель измеренный ветер как признак вообще**, а обучать прямо на NWP-признаках (тех же, что будут в проде), калибруя целевую переменную (мощность) через MOS/quantile mapping. Реалистичный уровень ошибки для одной турбины на day-ahead — **nRMSE ~15-20% от установленной мощности** (для парка/региона — вдвое меньше).
- **Вероятностный прогноз обязателен:** гетероскедастичность ошибки максимальна на крутом участке кривой мощности; quantile regression через pinball loss (как у победителя GEFCom2014) даёт прямую денежную ценность на балансирующем рынке. Foundation-модели временных рядов (Chronos, Moirai, TimeGPT) в задаче ветра с экзогенным NWP **пока не дают устойчивого выигрыша** над бустингом.

Key Findings

1. **Индустрия работает по схеме NWP→power, а не по чисто-временным рядам.** IEA Wind Task 36/51 прямо описывает: для day-ahead выход NWP-модели (скорость и направление ветра, иногда температура/стабильность) подаётся на вход статистических/ML-моделей, которые конвертируют это в мощность. (NREL) Лаги фактической выработки полезны только в первые часы.
2. **«Forecast-as-of-time» — это инфраструктурное требование, а не деталь.** Нужно эмулировать ровно те данные, что были доступны на момент выпуска. Open-Meteo предоставляет для этого три разных API (Historical Forecast, Previous Runs, Single Runs), а строгий запрет на реанализ (ERA5) в бэктесте — правильный, потому что ERA5 использует будущие наблюдения (look-ahead) и недоступен в реальном времени.
3. **Три стратегии обучения имеют разные компромиссы**, и практика расходится с наивным академическим подходом «обучать на ERA5».

4. **Победители соревнований — это бустинг с квантильной регрессией**, а не нейросети. GEFCom2014 wind track выиграла команда kPower на GBM с независимой подгонкой каждого квантиля и зоны.
 5. **Грязные данные SCADA решают фильтрами + доменными правилами**; ключевой нетривиальный вопрос — что делать с curtailment, и ответ зависит от того, что именно требует бизнес-метрика.
 6. **Правильная валидация — rolling-origin с привязкой к циклам NWP и разбивкой метрик по lead time**; сравнение всегда против персистентности и климатологии через skill score.
-

Details

1. Канонический производственный пайплайн (NWP-to-power)

Общая структура. По материалам IEA Wind Task 36 (Giebel et al., NREL/DTU) стандартный пайплайн day-ahead выглядит так: (1) NWP-модель (ECMWF IFS, GFS, ICON и т.д.) даёт прогноз метеополей на узлах сетки; (2) поля интерполируются/даунскейлятся к точке ВЭС; (3) статистическая или ML-модель (MOS — Model Output Statistics) конвертирует метеопрогноз в мощность и корректирует систематические ошибки NWP; (4) при наличии — ассимиляция онлайн-измерений SCADA для первых часов; (5) вывод детерминированного и вероятностного прогноза. Граница «метеорология ↔ ML» проходит на стадии (3): всё, что выше — это физика атмосферы (домен нацмет-центров: NOAA, DWD, ECMWF, MetOffice), всё, что ниже — статистический постпроцессинг и энергетическое моделирование (домен форкаст-вендоров и in-house команд).

Вендоры.

- **Vaisala (Xweather):** заявляет site-specific прогнозы до 230 часов вперёд, обновление каждые 5 минут, комбинацию NWP + статистических алгоритмов + AI, MAE «as low as $\pm 5\%$ » от номинала на hour-ahead и « $\pm 8\%$ » на day-ahead (Vaisala) (это маркетинговые цифры вендора для site-level, их надо воспринимать критически). Vaisala исторически «пионер NWP в оценке ветроресурса». (Vaisala)
- **ENFOR (Дания):** продукт WindFor™, основан на статистической школе DTU (Henrik Madsen, Pierre Pinson) — адаптивные регрессионные модели, инверсная трансформация через кривую мощности, цензурированная регрессия.
- **DNV, Meteologica, Solcast/Emerald** — аналогичные сервисы, отличаются в основном набором NWP-источников и калибровкой.

Разница вендор vs. in-house. Вендор имеет доступ к дорогим лицензионным NWP (полный ECMWF HRES/ENS через service agreement, собственные mesoscale-прогоны WRF), обслуживает тысячи площадок и потому калибрует глобальные модели. In-house команда генерирующей компании обычно имеет лучший доступ к «сырому» SCADA и знанию

о диспетчерских ограничениях, но ограничена в NWP — и всё чаще строит пайплайн именно на открытых данных (Open-Meteo, ECMWF Open Data, NOAA на AWS). Это и есть ваш сценарий.

2. Источники погоды и требование forecast-as-of-time

Открытые источники и практические детали:

- **Open-Meteo** — самый практичный вход для вашего кейса. Данные под CC-BY 4.0, без API-ключа, коммерческое использование разрешено (некоммерческое — до 10 000 запросов/день бесплатно). ([Open-Meteo](#)) Критично для бэктеста:
 - **Historical Forecast API**: непрерывный архив прогнозов с ~2021–2022, тот же формат, что у live Forecast API. Строится «сшивкой» первых часов каждого прогона ([Open-Meteo](#)) — то есть это near-nowcast, не строго правильный для длинных lead time.
 - **Previous Runs API**: временные ряды на фиксированном lead-time offset 1–7 дней, с января 2024 — именно для lead-time-stratified skill analysis. ([Open-Meteo](#))
 - **Single Runs API**: архив отдельных прогонов по точному init-time, ECMWF IFS HRES с марта 2024 — «for ML post-processing without look-ahead bias and operational backtesting». ([Open-Meteo](#)) Это правильный источник для строгого forecast-as-of-time.
 - Доступны ветер на 10/100/(и выше) м, температура; сервер open-source (AGPLv3), можно self-host для неограниченных запросов. ([Open-Meteo](#))
- **ECMWF Open Data**: IFS HRES 9 км (O1280), IFS/AIFS 0.25°, ENS 18 км. Лицензия CC-BY-4.0. Публикуется с задержкой ~2 часа против оперативной диссеминации (у 0.25° open-data), с октября 2025 задержку убрали. ([arxiv](#)) Циклы 00/06/12/18 UTC. AIFS — ML-модель ECMWF, только 6-часовые шаги на open-data. ([Open-Meteo](#))
- **NOAA GFS/GEFS**: глобально до 35 дней, разрешение ~0.25°, ([Open-Meteo](#)) доступ на AWS/Google Open Data. GEFS — ансамбль. Бесплатно.
- **DWD ICON**: ICON-Global (~13 км) публично и бесплатно ([Open-Meteo](#)) (opendata.dwd.de), но **сырые файлы удаляются через 24 часа — своего долгого архива нет** (Open Climate Fix ведёт архив ICON-Global с марта 2023 на HuggingFace в Zarr). ICON-EU (~7 км) и ICON-D2 (2.2 км) не покрывают Казахстан.

Покрывание Казахстана/Центральной Азии. Региональные модели высокого разрешения (HRRR — только США; ICON-D2, AROME — только Европа) **не покрывают Казахстан**. Для вашей точки доступны только глобальные модели: **ECMWF IFS (9 км, лучший), ICON-Global (~13 км), GFS (~25 км)**. Это ключевое ограничение — рассчитывать на mesoscale-разрешение нельзя.

Проблема отсутствия длинной истории архивных прогнозов — центральная. Три конкурирующие стратегии:

(а) Обучать на реанализе ERA5, инференс на прогнозах. Плюс: ERA5 даёт длинную (с 1940), консистентную, gap-free историю на 10 и 100 м. Минус: train/serve skew — ERA5 «ближе к правде», чем реальный прогноз, потому что ассимилирует наблюдения (в т.ч. будущие относительно момента прогноза). Модель, обученная на «слишком хорошем» ветре, в проде получает более шумный NWP-прогноз и деградирует. Эмпирически: Hardy et al. (2025, *Meteorological Applications*, DOI 10.1002/met.70038) обучали CNN на 12-14 годах ERA5 и инференс делали на оперативных прогнозах AIFS, **специально верифицируя против оперативного анализа ECMWF, а не против ERA5**, (Royal Meteorological...) — прямое признание проблемы mismatch. Известно, что ERA5 систематически недооценивает скорость ветра (особенно в горах) и требует bias-коррекции. (arxiv)

(б) Обучать на историческом архиве прогнозов с той же lead-time структурой. Это best practice, но упирается в короткую историю архива (Open-Meteo с ~2021, ECMWF IFS Single Runs с марта 2024). Плюс: train и serve видят одинаково «шумный» ветер, модель учится корректировать именно ошибки NWP по каждому lead time. Dabernig et al. (2017, *Weather and Forecasting*, DOI 10.1175/WAF-D-15-0095.1) показали на австрийских/немецких парках, что длинный reforecast-архив (с той же lead-time структурой) при MOS-подгонке компенсирует более слабое разрешение: ECMWF-reforecast работает на уровне более высокоразрешающей оперативной модели за счёт длины обучения. При этом слабый архив (NOAA GEFS 2-го поколения) заметно хуже. (American Meteorolo...)

(в) Двухступенчатая схема: физическая кривая мощности + ML-коррекция ошибки NWP. Прогноз ветра → физическая/эмпирическая кривая мощности (baseline) → ML-модель предсказывает остаток (ошибку). Это MOS-школа Messner/Zeileis/ENFOR (инверсная трансформация через кривую мощности + цензурированная регрессия, Messner et al. 2014, *Wind Energy* 17:1753). Эмпирически (Xia et al. 2026, *Renewable Energy* 261:125263, парки в пустыне Гоби, NW Китай): AI/MOS-постпроцессинг даёт ~20% снижения RMSE, тогда как смена NWP-источника GFS→ECMWF HRES — лишь 3-4%. (sciencedirect) Важный caveat: MOS-коррекция подавляет изменчивость прогноза на 20-30%, ухудшая захват экстремумов и рампов (sciencedirect) — это невидимо в RMSE, но критично для балансирующего рынка.

Вывод по стратегиям для вашего кейса: оптимально комбинировать (б) и (в) — обучать двухступенчатую модель на архиве прогнозов (Open-Meteo Historical Forecast / ECMWF IFS Single Runs), а ERA5 использовать только для восстановления пропущенных признаков в истории SCADA и для оценки плотности воздуха, но **не как основной источник обучения для инференса на прогнозах.**

3. Train/serve skew между измеренным и прогнозным ветром

Это ядро вашей проблемы. В истории — ветер с анемометра гондолы (nacelle anemometer), в проде — NWP-ветер на 10/100 м. Наивное решение «обучить модель мощность ← ветер_гондолы, а в проде подать NWP-ветер» **ломается**, потому что:

- Анемометр гондолы искажён вращением ротора и корпусом (нужна nacelle transfer function, NTF, по IEC 61400-12-2/-12-6); NTF зависит от стабильности атмосферы и турбулентности (St. Martin, Lundquist, Clifton, *Wind Energy Science* 2:295, 2017 — коррекция через NTF даёт АЕР в пределах 1% от значения по upwind-мачте).
- NWP-ветер имеет совершенно другое распределение ошибок, чем измеренный ветер.

Best practice (и здесь практика прямо расходится с наивной академической постановкой «power curve от измеренного ветра»): обучать модель **на тех же признаках, что будут в проде** — то есть на NWP-ветре (10 и 100 м), полностью игнорируя измеренный ветер как входной признак. Измеренный ветер гондолы полезен только офлайн — для (1) построения/чистки эмпирической кривой мощности, (2) оценки шира ветра, если есть измерения на нескольких высотах. Целевая переменная — фактическая нормированная мощность.

Экстраполяция к высоте ступицы. Если NWP даёт 10 и 100 м, hub-height (обычно ~80–120 м) получают:

- **Степенной закон** $v_h = v_{ref}(h/h_{ref})^\alpha$; классический $\alpha = 1/7 \approx 0.143$, но это грубо. Jung & Schindler (2021, *Int. J. Energy Research*, DOI 10.1002/er.6382) на глобальных данных 10/100 м показали, что фиксированный $\alpha = 0.14$ даёт заметную ошибку capacity factor. Лучше ****оценивать α динамически**** из пары уровней 10 и 100 м самого NWP (log-log регрессия) — это даёт time-varying shear, косвенно кодирующий стабильность атмосферы.
- **Логарифмический профиль** и теория подобия **Монина-Обухова** — точнее физически, но требуют шероховатости/потоков тепла, которых у вас нет. На практике для одной турбины избыточно.
- Прагматично: подавайте в модель **и 10 м, и 100 м ветер как отдельные признаки** + их отношение (это и есть эмпирический shear); пусть градиентный бустинг сам выучит нелинейное отображение на hub-height мощность. Это устраняет необходимость явной экстраполяции.

Калибровка/MOS. Систематический bias NWP убирают через MOS, quantile mapping (сопоставление CDF прогноза и факта), либо просто позволяют ML-модели выучить bias по lead time.

Плотность воздуха (IEC 61400-12-1). Мощность $\propto$ плотности воздуха ρ . Стандарт предписывает нормировку скорости ветра: $(\text{SkySpecs}) v_\rho = v(\rho/\rho_0)^{1/3}$, где $\rho_0 = 1.225 \text{ кг/м}^3$

м³. ρ считается из температуры, давления и влажности. (SkySpecs) **У вас есть температура (это ценно!), но нет давления и влажности.** Практика (SkySpecs; DTU, Jung et al. 2019, *Energies* 12:2038): давление/влажность берут из реанализа/NWP по ближайшему узлу — «использование ближайшего узла ERA5 — вероятно, самый точный способ оценки ρ , когда измерения дальше 10 км». (Dtu) Казахстан — высокие абсолютные отметки многих площадок → ρ заметно ниже 1.225 → без коррекции будет систематическая переоценка мощности. **Рекомендация: добавьте температуру (есть в SCADA) и давление из NWP как признаки; либо явно посчитайте ρ и нормируйте.**

4. Модели и признаки

Что реально в проде:

- **Градиентный бустинг (LightGBM/XGBoost/CatBoost)** — рабочая лошадка. Прямое multi-horizon предсказание, легко даёт квантили (pinball loss), устойчив к пропускам, быстрый. В бенчмарке UniWind (2026) LightGBM/XGBoost дают nRMSE ~18-22% на day-ahead по регионам (напр. LightGBM 18.30% / XGBoost 18.20% в зоне SD), обгоняя «модные» трансформеры (PatchTST 33.77%, iTransformer 33.76% — хуже даже наивной power curve на 30.18%).
- **Линейные/GAM** — база MOS-школы (ENFOR; Nagy et al. GEFCom2014 — generalized additive tree ensemble).
- **seq2seq/LSTM/TCN** — лучше только на ультра-коротком горизонте (первые часы), где важна авторегрессия; на 24-48 ч преимущество исчезает.
- **Temporal Fusion Transformer, N-BEATS/N-HiTS** — в статьях выигрывают, но в проде на одной турбине с экзогенным NWP выигрыш над бустингом неустойчив и не окупает сложность; трансформер склонен переобучаться на шум ряда (прямая цитата из Powerformer-работы: «the Transformer model may fit the redundant noises of the time series data and thus presents poor test performance»).
- **Foundation-модели (TimeGPT, Chronos, Moirai, TiRex):** в бенчмарках энергетики (ERCOT load/wind, ARPA-E PERFORM) они конкурентны в zero-shot, но **для ветра выигрыш меньше, чем для солнца/нагрузки**, и решающую роль играют экзогенные погодные признаки, а не сама foundation-архитектура (nMAE Moirai-L улучшается лишь с 4.03% до 3.65% при добавлении погодных экзогенов; для ветра прирост от удлинения контекста слабее, чем для солнца). Устойчивого превосходства над хорошо настроенным бустингом с NWP-признаками нет.

«Одна модель на все горизонты» vs. «модель на каждый lead time». Классика — отдельная модель на каждый lead time (как у победителя GEFCom2014: каждая зона × квантиль отдельно). Современный компромисс — **одна модель с lead time как признаком** (lead-time-continuous). Работа по MOGREPS-G (per-lead-time-continuous постпроцессинг) показала, что lead-time-continuous модели дают сопоставимое или даже лучшее качество

при малых данных и экономят вычисления. Для вашего кейса (мало данных — ~3 года, месяц выпал) рекомендую одну модель с lead time как признаком — это устойчивее к переобучению.

Типовой набор признаков:

- Скорость ветра NWP на 10 и 100 м; их отношение (shear).
- Направление ветра через sin/cos — у вас в истории его нет, но в NWP-прогнозе оно есть; это важный признак (эффекты рельефа, wake). Используйте NWP-направление.
- Порывистость (gust/mean), если NWP даёт gust.
- Оценка стабильности атмосферы через shear или градиент температуры.
- Градиенты между соседними узлами сетки NWP (кодируют прохождение фронтов).
- Lead time; час init-цикла.
- Календарные/сезонные фичи (час суток, месяц, sin/cos годового цикла).
- Температура (есть в SCADA и NWP) → плотность воздуха.
- **Лаги фактической выработки** — полезны только на первые ~3–6 ч; на 24–48 ч бесполезны, потому что автокорреляция мощности за сутки распадается (ветер за сутки почти некоррелирован). В day-ahead проде их часто вообще нет (нет свежего факта на момент выпуска), поэтому строить на них нельзя.

Соревнования:

- **GEFCom2014 wind track:** победила команда **kPower** (Landry, Erlinger, Patschke & Varrichio, *Int. J. Forecasting* 32(3):1061–1066, 2016). Прямая цитата метода: «We used gradient boosted machines (GBM) for multiple quantile regression, fitting each quantile and zone independently»; на основе pinball loss команда «finished first overall, and first in 11 of the 12 individual tasks» (второе место в оставшейся). Ключевой признак — «bidirectional lagged 100 m wind energy forecasts». Три из пяти лучших моделей использовали квантильную регрессию. ([Semantic Scholar](#))
- **Kaggle/HEFTCom2024:** стекинг NWP-источников (ICON+GFS) улучшал pinball-loss на 6–11% против одиночного источника.

5. Ансамблирование и вероятностный прогноз

Multi-model blending. Комбинация нескольких NWP почти всегда бьёт лучшую одиночную модель:

- Yakoub, Mathew & Leal (2023, *Heliyon* 9(11):e21479, ВЭС Смёла, Норвегия, 68 турбин, ECMWF-IFS + UKMO-EURO4 + MEPS, горизонт 24–48 ч): **комбинация 3 NWP снижает nRMSE/nMAE на 8–22%** относительно одиночных. ([ScienceDirect](#)) Прямая цитата: «NRMSE values were 7.8 %, 8.7 %, 9.2 % and 10 %, respectively [MIX, IFS, EURO, MEPS]» — то есть MIX 7.8% против лучшей одиночной IFS 8.7% (~10% относительного

выигрыша). Веса — обратно-квадратичные к RMSE за последние часы (ScienceDirect (recency-weighted, т.е. **режимно-зависимые**).

- von Bremen (OSTI 21002339, ECMWF + HIRLAM, оффшор Middelgrunden): прямая цитата — «The normalized day-ahead RMSE forecast error for Middelgrunden can be reduced by 1% compared to single ECMWF. This is a relative improvement of 6%. For lead times >24h it is worthwhile to use a more sophisticated model combination approach than simple linear weighting» (регрессия на главные компоненты вместо простого линейного взвешивания).

Вероятностные методы:

- **Quantile regression через pinball loss** — стандарт де-факто (GEFCom2014). В LightGBM обучают отдельную модель на каждый квантиль (0.1...0.9), проблема — quantile crossing (лечат сортировкой/монотонными ограничениями).
- **NGBoost** — natural gradient boosting, предсказывает параметры распределения (напр., усечённого нормального), даёт непрерывную плотность.
- **Conformal prediction** — distribution-free интервалы с гарантией покрытия; хорошо работает поверх XGBoost (напр., Eskom, Южная Африка, PLAQR-averaging + conformal).
- **Ансамблевая дисперсия как признак** (spread из GEFS/ENS) — кодирует режимную неопределённость.

Гетероскедастичность. Ошибка мощности максимальна на **крутом участке кривой мощности** (между cut-in ~3 м/с и rated ~12 м/с): там малая ошибка ветра даёт большую ошибку мощности (dP/dv максимально, $P \propto v^3$). У насыщения (rated-cutout) и ниже cut-in ошибка мала. Это учитывают: (1) гетероскедастичными GP (Rogers et al.; Ladopoulou et al. 2025, arXiv:2505.09026), (2) квантильной регрессией (интервалы естественно расширяются на крутом участке), (3) моделированием ветра, а не мощности, с последующим прогоном через кривую (неопределённость ветра гомоскедастична, а нелинейность кривой создаёт гетероскедастичность мощности «бесплатно»).

Ценность на рынке. IEA Wind Task 51 (Möhrlen, Zack, Bjerregård & Giebel — «IEA Wind Recommended Practice for the Implementation of Renewable Energy Forecasting Solutions», Elsevier Academic Press, 2022, ISBN 9780443186813, DOI 10.1016/C2021-0-03549-5) прямо посвящён ценности вероятностных прогнозов: на балансирующем рынке вероятностный прогноз позволяет оптимизировать bidding под штрафы за отклонение (асимметричная функция потерь → оптимальна не медиана, а определённый квантиль). Экономическую ценность точности зафиксировал в письменном свидетельстве в Комитет по науке Палаты представителей США Dr. David Mooney (NREL), цитируя J. Charles Smith (2009, FERC): «Xcel Energy... has released analysis that shows every percentage point improvement in accuracy saves Xcel Energy \$1.2 million through a reduction in required spinning reserves».

Реалистичные величины ошибок (тот же источник, Smith 2009): **одиночный парк — day-ahead 10-12% capacity / 25-30% energy; регион — 6-8% capacity / 15-18% energy.** (house)

6. Работа с грязными данными SCADA

Что выявляют и как:

- **Curtailement (ограничения выдачи):** точки, где ветер высокий, а мощность искусственно занижена/нулевая. Детектируют по отклонению от нормальной кривой мощности + (если есть) сигналам оператора. У вас сигналов нет → детекция только по геометрии кривой (bidirectional quartile analysis + curtailement detection).
- **Простои/техобслуживание:** нулевая мощность при рабочем ветре.
- **Обледенение лопастей:** недовыработка при низких температурах и высокой влажности — у вас есть температура, это помогает.
- **Залипшие датчики:** константные значения подряд.
- **Выбросы вне кривой мощности:** методы фильтрации — биннинг по IEC + квантильные отсечки; **Isolation Forest** (McKinnon et al.; Morrison et al. 2022 использовали iForest + LOF + GMM + KNN); (ScienceDirect) **DBSCAN** и гибриды **iForest+DBSCAN; iForest + mean-shift; Gaussian Process / heteroscedastic GP** для «normal behaviour power curve». Один из отчётов (Pandit & Infield / ScienceDirect S0960148118302258): GP-фильтрация улучшила средний RMSE кривой с 45.5 до 30.7 кВт и AEP-ошибку с 1.98% до 0.71%. Типично **после чистки остаётся ~31% исходных данных** (ResearchGate) (агрессивно; McKinnon-подобные пайплайны).

Ключевой вопрос: исключать ли curtailement из обучения? Здесь практика тонкая:

- Если бизнес-метрика требует предсказывать **фактическую выработку, включая ограничения** (ваш случай — прод предсказывает то, что реально пойдёт в сеть), то полное исключение curtailement из обучения **создаёт систематический сдвиг вверх:** модель выучит «идеальную» кривую и будет переоценивать в периоды ограничений.
- Но curtailement обычно **непредсказуем из погоды** (это диспетчерское решение), поэтому обучать модель воспроизводить его по ветру — значит вносить шум.
- **Компромисс (best practice):** обучать «чистую» модель мощности на данных без curtailement (чтобы выучить физическую связь ветер→мощность), а влияние ограничений моделировать отдельно/принимать как неустранимую ошибку. Либо — если ограничения редки — оставить их в обучении и принять размытие. Для Казахстана без данных о curtailement реалистично: пометить подозрительные периоды фильтром, обучить основную модель на чистом подмножестве, но **честно репортить метрику на всём тестовом месяце, включая непредсказуемые ограничения** (иначе бэкtest будет оптимистично смещён).

Длинные пропуски (месяц подряд). Не интерполировать длинные пропуски — это создаст фантомные данные. Практика: (1) просто исключить период из обучающих окон (бустинг это переносит нормально, ему не нужна непрерывность, в отличие от LSTM); (2) короткие пропуски (<1-2 ч) можно интерполировать; (3) 6,6% разрозненных пропусков — не критично для tree-based моделей, которые работают с NaN нативно (LightGBM). **Именно это — ещё один аргумент за бустинг, а не за seq2seq/LSTM**, которым непрерывность ряда критична.

7. Методология валидации

Rolling-origin (walk-forward) бэктест — единственно корректный для forecast-систем:

- Для каждого дня тестового месяца эмулируйте момент выпуска прогноза (напр., 06:00 UTC), берите **только те NWP-прогоны, что были опубликованы к этому моменту** (с учётом задержки диссеминации ~2 ч), и только историю SCADA до cut-off. Прогнозируйте 24-48 ч вперёд почасово. Сдвигайте origin на сутки, прогоняйте весь месяц.
- **Привязка к циклам NWP (00/06/12/18 UTC):** lead time считается от init-цикла, а не от календаря. Прогон 00 UTC для часа 36 — это другой lead time, чем прогон 12 UTC для того же часа.
- **train-only preprocessing:** любые скейлеры/квантильные мэппинги фитятся только на train до origin, применяются к forecast-инстансу (иначе утечка).
- **Разбивка метрик по lead time** обязательна — ошибка растёт с горизонтом.

Метрики индустрии:

- **nRMSE, nMAE** в % от установленной мощности ($nRMSE = RMSE/P_rated \times 100\%$). Это стандарт (UniWind, IEA).
- **Bias (nMBE)** — знак систематической ошибки.
- **Skill score** относительно персистентности и климатологии: $SS = 1 - RMSE_{model}/RMSE_{ref}$. Для 24-48 ч персистентность — слабый baseline (ветер за сутки декоррелирует), поэтому референс — климатология или суточно-циклическая персистентность. Для энергетики skill score >0.3 против персистентности на 24-48 ч считается значимым улучшением.
- **Pinball loss (quantile score)** и **CRPS** — для вероятностных прогнозов. Инструменты IEA Task 51: `evalprob4cast` (R-пакет), `WE-verify-prob`.

Реалистичные значения nRMSE для одной турбины на 24-48 ч:

- **Одна турбина, day-ahead:** nRMSE ~15-20% от номинала (energy error 25-30% по Smith 2009; capacity error 10-12%). Бенчмарк UniWind: LightGBM/XGBoost 18-22%

nRMSE по регионам. Для одной турбины (нет сглаживания усреднением по парку) ошибка выше, чем для парка.

- **Парк: ~10-15% nRMSE; регион: ~6-8% capacity error** — за счёт пространственного сглаживания (ошибки турбин частично компенсируются).
 - **Важное расхождение с академикой:** многие статьи репортят $R^2 > 0.95$ и nRMSE ~11% — но это либо на **измеренном/реанализном** ветре (не forecast!), либо на парке/регионе. Как только переходят на **реальный прогноз погоды**, ошибка вырастает в разы: в работе про 7-МВт оффшорную турбину на тесте MAE был 194 кВт (R^2 0.98), а на деплое с прогнозными входами — MAE ~1462 кВт, **разница почти в 7 раз**. Авторский вывод: «forecast accuracy, not model fitting, is the next constraint on real-world use» — это ровно ваш случай. **Не ждите nRMSE <15% на одной турбине с публичным NWP на 24-48 ч; 15-22% — реалистичный, честный диапазон.**
-

Recommendations

Этап 0 — данные и baseline (неделя 1-2):

1. Заберите архив прогнозов через **Open-Meteo Historical Forecast API** (модели ECMWF IFS и ICON-Global), переменные: `wind_speed_10m`, `wind_speed_100m`, `wind_direction_10m/100m`, `temperature_2m`, `wind_gusts_10m`, `surface_pressure`. Для строгого бэктеста на свежих датах используйте **Single Runs API (ECMWF IFS с марта 2024)**.
2. Восстановите давление/влажность из NWP/ERA5 для расчёта плотности воздуха; нормируйте по IEC 61400-12-1.
3. Baseline: эмпирическая кривая мощности (бининг NWP-ветра 100 м → медианная мощность) + персистентность. Это ваша точка отсчёта для skill score.

Этап 1 — основная модель (неделя 3-5): 4. **LightGBM, прямой multi-horizon, quantile objective** (квантили 0.1/0.5/0.9), одна модель с **lead time как признаком**. Признаки: ветер 10/100 м, их отношение, направление sin/cos (из NWP), gust/mean, температура, плотность воздуха, градиенты между узлами, календарь, час init-цикла. **Не подавайте измеренный ветер гондолы**. 5. Двухступенчато: обучите LightGBM предсказывать **остаток** между фактической мощностью и baseline-кривой (MOS-коррекция ошибки NWP). 6. Чистка SCADA: iForest + квантильные отсечки по бинам; пометьте curtailment; обучайте на чистом подмножестве, но **тестируйте на всём месяце**.

Этап 2 — ансамбль и вероятность (неделя 6-7): 7. Multi-model blending ECMWF IFS + ICON-Global + GFS с recency-weighted весами (обратно-квадрат RMSE за последние N дней). Ожидаемый выигрыш 8-15% nRMSE (по Yakoub et al. 2023 — до ~10% относительно лучшей одиночной модели). 8. Добавьте ансамблевый spread (GEFS/ENS) как признак неопределённости; калибруйте интервалы conformal prediction.

Этап 3 — агентный пайплайн и бэктест (неделя 8): 9. Rolling-origin по всему тестовому месяцу, эмуляция cut-off и задержки диссеминации, метрики по lead time (nRMSE, nMAE, bias, skill vs климатология, pinball, CRPS). 10. Агентные стадии: забор погоды (по расписанию циклов 00/06/12/18 UTC) → чистка/фичи → инференс → почасовые квантили → анализ (сравнение с фактом по мере поступления) → перерасчёт при новом NWP-прогоне.

Пороги, меняющие решения:

- Если nRMSE одиночной модели <15% на 24-48 ч — проверьте на утечку (не подмешался ли реанализ/факт).
 - Если foundation-модель (Chronos/TiRex) не бьёт LightGBM на >3% skill в вашем бэктесте — не тащите её в прод.
 - Если multi-model blending даёт <5% выигрыша — оставьте одну ECMWF IFS (проще эксплуатировать).
 - Если bias по lead time систематичен — добавьте quantile mapping/MOS-калибровку на train.
-

Caveats

- **Маркетинговые цифры вендоров** (Vaisala $\pm 5\%$ / $\pm 8\%$) относятся к site-level с полным набором сенсоров и лицензионным NWP; на вашей одиночной турбине с публичным NWP они недостижимы. Воспринимайте их критически.
- **Чистого числа «на сколько % деградирует ERA5-trained → forecast-served модель»** в открытой литературе нет — эффект документирован качественно (у Dabernig et al. 2017 — через качество reforecast-архива; в европейской платформенной работе — «slightly worse» для модели на реанализе). Это разрыв в доказательной базе; проверьте на своих данных.
- **Foundation-модели** развиваются быстро (Chronos-2, Moirai-2, TiRex 2025–2026); мой вывод «нет устойчивого выигрыша в ветре с NWP» отражает бенчмарки на середину 2026 и может измениться — но требует вашей собственной проверки на бэктесте, а не веры в лидерборды.
- **Отсутствие направления ветра и давления в истории SCADA** не критично, потому что best-practice-подход всё равно берёт их из NWP, а не из SCADA. Но отсутствие данных о **curtailment** и **доступности турбины** — это неустранимый источник ошибки: часть отклонений в тестовом месяце будет непредсказуема принципиально.
- **Казахстан:** только глобальные NWP (нет mesoscale), сложный/континентальный климат, возможны сильные суточные циклы стабильности атмосферы (ночной низкоуровневый джет) — это делает shear-признаки особенно ценными, но и повышает базовую ошибку.

- Числа nRMSE из разных источников не всегда сопоставимы (нормировка на rated vs на mean, турбина vs парк, forecast vs reanalysis input) — при сравнении всегда проверяйте знаменатель и тип входа.
-

Ключевые источники

- IEA Wind Task 36 — Giebel et al., «Wind power forecasting: IEA Wind Task 36 & future research issues» (docs.nrel.gov/docs/fy17osti/67542.pdf); iea-wind.org/task36.
- IEA Wind Task 51 — Möhrle, Zack, Bjerregård & Giebel, «IEA Wind Recommended Practice for the Implementation of Renewable Energy Forecasting Solutions», Elsevier 2022, DOI 10.1016/C2021-0-03549-5; iea-wind.org/task51.
- Open-Meteo: docs Historical Forecast / Previous Runs / Single Runs / ECMWF API (open-meteo.com).
- ECMWF Open Data (ecmwf.int/en/forecasts/datasets); DWD ICON (dwd.de); NOAA GFS/GEFS (AWS Open Data).
- Landry, Erlinger, Patschke & Varrichio (2016), «Probabilistic gradient boosting machines for GEFCom2014 wind forecasting», *Int. J. Forecasting* 32(3):1061–1066.
- Dabernig, Mayr, Messner & Zeileis (2017), «Predicting Wind Power with Reforecasts», *Weather and Forecasting* 30(6), DOI 10.1175/WAF-D-15-0095.1.
- Messner et al. (2014), *Wind Energy* 17:1753 (инверсная трансформация + цензурированная регрессия).
- Hardy et al. (2025), *Meteorological Applications*, DOI 10.1002/met.70038 (ERA5-train / AIFS-serve).
- Xia, Luo, Li & Chang (2026), *Renewable Energy* 261:125263 (ECMWF vs GFS + AI-постпроцессинг, Гоби).
- Yakoub, Mathew & Leal (2023), *Heliyon* 9(11):e21479 (multi-model blending, Смёла).
- von Bremen, OSTI 21002339 (ECMWF+HIRLAM combination, Middelgrunden).
- St. Martin, Lundquist & Clifton (2017), *Wind Energy Science* 2:295 (nacelle transfer function).
- Jung & Schindler (2021), *Int. J. Energy Research*, DOI 10.1002/er.6382 (power-law exponent); Jung et al. (2019), *Energies* 12:2038 (air density из реанализа).
- IEC 61400-12-1:2022 (air density normalization, power performance).
- UniWind (2026, arXiv:2607.01670) — day-ahead nRMSE бенчмарк моделей; Ladopoulos et al. (2025, arXiv:2505.09026) — heteroscedastic GP.
- Mooney/Smith (2009), «Lessons Learned in Wind Integration», письменное свидетельство в Комитет по науке Палаты представителей США (science.house.gov) — величины ошибок и экономия Xcel Energy.